

TRAVAIL PRATIQUE — DATA & INTELLIGENCE ARTIFICIELLE

Prédiction de la réussite d'un étudiant avec le Machine Learning

Niveau : Débutant / Intermédiaire Durée indicative : 2 à 3 heures

1. Contexte

Une école souhaite utiliser l'Intelligence Artificielle afin d'identifier les étudiants qui ont de fortes chances de réussir ou d'échouer à leur examen final. Vous disposez d'un historique de 300 étudiants contenant différentes informations sur leur comportement, leur assiduité et leurs résultats.

Votre mission consiste à construire un modèle de Machine Learning capable de prédire la réussite d'un nouvel étudiant.

2. Objectif

Développer en Python une IA capable de répondre à la question : « Cet étudiant a-t-il de fortes chances de réussir son examen final ? »

Variable cible : reussite — 0 = échec, 1 = réussite.

3. Jeu de données

Variable	Description
heures_etude_semaine	Nombre d'heures d'étude par semaine
taux_presence_pct	Taux de présence aux cours (%)
exercices_realises	Nombre d'exercices réalisés
note_controle_continu	Note obtenue au contrôle continu /20
temps_plateforme_h_semaine	Temps passé sur la plateforme pédagogique par semaine
devoirs_rendus	Nombre de devoirs rendus
participation_classe_10	Niveau de participation en classe /10
reussite	Résultat final : 0 = échec, 1 = réussite

4. Travail demandé

Partie 1 — Exploration des données

- Charger le fichier CSV avec Pandas.
- Afficher les premières lignes.
- Afficher le nombre d'étudiants et de variables.
- Identifier les types des variables.
- Rechercher les valeurs manquantes.
- Afficher les statistiques principales des variables numériques.
- Observer la répartition entre étudiants ayant réussi et échoué.

Partie 2 — Analyse des données

- Réaliser au minimum deux graphiques avec Matplotlib ou Seaborn.
- Exemples : heures d'étude vs réussite, taux de présence vs réussite, note de contrôle continu vs réussite, répartition des résultats.
- Répondre à la question : quelles variables semblent avoir une influence sur la réussite ?

Partie 3 — Préparation des données

- Traiter les valeurs manquantes.
- Séparer les variables explicatives X et la variable cible y.
- Diviser les données en 80 % pour l'entraînement et 20 % pour le test.
- Expliquer brièvement les choix effectués.

Partie 4 — Création de l'IA

- Utiliser Scikit-learn pour entraîner une Logistic Regression.
- Entraîner le modèle sur les données d'entraînement.
- Prédire la réussite des étudiants du jeu de test.

Partie 5 — Évaluation

- Calculer Accuracy, Precision, Recall et F1-score.
- Afficher la matrice de confusion.
- Déterminer si le modèle est suffisamment performant pour identifier les étudiants à risque.
- Justifier la réponse à partir des résultats.

5. Prédiction d'un nouvel étudiant

Créer une fonction permettant de fournir les informations d'un nouvel étudiant et d'obtenir une prédiction ainsi qu'une probabilité de réussite.

```
etudiant = {
    "heures_etude_semaine": 12,
    "taux_presence_pct": 91,
    "exercices_realises": 25,
    "note_controle_continu": 15,
    "temps_plateforme_h_semaine": 8,
    "devoirs_rendus": 9,
    "participation_classe_10": 8
}
```

Exemple de résultat : Probabilité de réussite : 87,4 % — Prédiction : RÉUSSITE PROBABLE.

6. Bonus — Random Forest

Entraîner un deuxième modèle avec Random Forest, puis comparer les deux modèles.

Modèle	Accuracy	Precision	Recall	F1-score
Logistic Regression				
Random Forest				

Question : quel modèle choisiriez-vous et pourquoi ?

7. Question finale — Limites de l'IA

Imaginez que votre modèle indique : « Cet étudiant possède seulement 35 % de chances de réussir. » L'école souhaite utiliser cette information pour proposer un accompagnement personnalisé. Quels seraient les risques de prendre une décision uniquement à partir de la prédiction de l'IA ? Donnez au moins deux limites de votre système.

8. Livrables

- Un notebook Jupyter (.ipynb) contenant le code Python, les graphiques, les résultats et les interprétations.
- Une courte conclusion présentant les performances obtenues, le modèle choisi et les limites de l'IA.

9. Technologies

Python • Pandas • NumPy • Matplotlib / Seaborn • Scikit-learn • Jupyter Notebook